





BOURBAKI

COLEGIO DE MATEMÁTICAS

Python para Ciencia de Datos en la era de la IAGen

(2026)




El Colapso de la Confianza Ciega

3%

CONFIANZA PLENA EN IA ¹

La mayor frustración de los desarrolladores (citada por el 66%), es lidiar con "soluciones de IA que son casi correctas, pero no del todo", lo que a menudo conduce a la segunda mayor frustración: "Depurar código generado por IA consume más tiempo" (45%).

Python se ha convertido discretamente en el lenguaje predeterminado para la próxima década de la informática, desde agentes de IA hasta dispositivos periféricos y pipelines de datos empresariales ²




La confianza es el la piedra angular del valor que puede dar la IA Gen

- La **calidad de los datos** y las inconsistencias en los pipelines de datos es el problema más común cuando se trata de poner en producción proyectos de CD y modelos de AI.

Relevancia de Pandas

- **Última Milla:** Es la herramienta final para limpiar, ordenar y estructurar los datos antes de entrar a un modelo de ML.
- **Integración con el Ecosistema de ML e IA:** Conexión nativa con Scikit-Learn, TensorFlow, PyTorch, LlamaIndex/Lama Chain (para modelos RAG)
- **Interoperabilidad:** Se usa en Spark, Snowflake y Dask sin cambiar el código.



Objetos Fundamentales de Pandas

SERIES

La base unidimensional.
Fundamental para entender tipos de datos (dtypes) y alineación de índices.

Cada columna en un modelo de ML es una Serie.

DATA FRAME

El estándar bidimensional. Es el "Excel programable" donde ocurre toda la ingeniería de variables (features)

Es la unidad mínima que aceptan librerías como Sckit Learn, XGBoost o TensorFlow. Es donde se integran múltiples fuentes de datos en una sola tabla.

Importancia de Pandas en el Flujo de Datos

Limpieza y Transformación

Valores Nulos

`.fillna()`, `.dropna()`, `.interpolate()`

Tipos de Datos

`.astype()`, `pd.to_datetime()`

Cadenas de Texto

`.str.replace()`, `.str.contains()`

Reestructuración

`.pivot_table()`, `.melt()`

Análisis Exploratorio (EDA)

Perfiles Estadísticos

`.describe()`, `.info()`

Agrupación de Datos


`.groupby()`, `.agg()`

Relaciones y Frecuencias

`.corr()`, `.value_counts()`

Visualización Rápida

`.plot()`, `.hist()`, `.boxplot()`



Indexadores en Pandas de acceso a los datos

```
df.loc[ 'SKU123' , 'Precio' ]
```

Indexador basado en Etiquetas

Prioridad: Es más legible y menos propenso a errores cuando las tablas cambian de forma.

```
df.loc[ 5 , 3 ]
```

Indexador basado en posición entera

Prioridad: Es más legible y menos propenso a errores cuando las tablas cambian de forma.



Principales Métodos de Filtrado

Boolean Indexing

Uso de máscaras lógicas.

```
df[df['edad'] > 18]
```

Es el método más potente y flexible para condiciones complejas.

.isin()

Filtrado categórico.

```
df[df['pais'].isin(['MX', 'ES'])]
```

Limpio y eficiente para comparar contra listas de valores.

.query()

Sintaxis tipo SQL.

```
df.query("ventas>1000")
```

Máxima legibilidad. Ideal para compartir código con analistas de negocio

GRACIAS

